

**UNIVERSIDAD PRIVADA DE TACNA
FACULTAD DE INGENIERIA
ESCUELA PROFESIONAL DE INGENIERIA DE SISTEMAS**

PLAN DE TRABAJO DE INVESTIGACION

**"ECOSISTEMA DE GESTIÓN DOCUMENTAL INTELIGENTE,
CLASIFICACIÓN AUTÓNOMA Y CIBERSEGURIDAD PARA
ORGANIZACIONES DE SERVICIOS DE TACNA, 2026"**

PARA OPTAR:

TITULO PROFESIONAL DE INGENIERIA DE SISTEMAS

PRESENTADO POR:

Bach. Ahmed Hasan Akhtar Oviedo; Bach. Carlos Daniel Ayala Ramos

TACNA - PERU

2026

INDICE

I. DATOS GENERALES	7
1.1 Título	7
1.2 Área de investigación	7
1.3 Línea de investigación	7
1.4 Autor(es)	7
1.5 Asesor	7
II. EL PROBLEMA DE INVESTIGACIÓN	7
2.1 Descripción del problema	7
2.2 Formulación del problema	8
2.3 Justificación e importancia	8
2.4 Objetivos	9
2.5 Hipótesis	9
2.6 Tipo y nivel de investigación	10
2.7 OPERACIONALIZACIÓN DE VARIABLES	10
III. MARCO TEÓRICO	14
3.1 Antecedentes de la investigación	14
3.2 Bases teóricas	15
3.2.1 Gestión documental y digitalización	15
3.2.2 Clasificación autónoma con inteligencia artificial	15
3.2.3 Ciberseguridad documental: cifrado y protección de datos sensibles	15
3.2.4 Logs inmutables y trazabilidad	15
3.2.5 Sincronización en la nube	16
3.2.6 Normas de citación de tablas, figuras y ecuaciones	16
3.3 Definición de términos	16
3.3.1 Ecosistema de gestión documental inteligente	16

3.3.2 Clasificación autónoma	16
3.3.3 OCR (reconocimiento óptico de caracteres)	16
3.3.4 Cifrado de PDF	16
3.3.5 Logs inmutables	16
3.3.6 Trazabilidad	16
3.3.7 Sincronización en la nube	17
3.3.8 Documento administrativo	17
3.3.9 Falsos positivos/negativos en clasificación	17
3.3.10 Sesiones de captura	17
IV. MARCO METODOLÓGICO	17
4.1 Diseño de investigación	17
4.2 Acciones y actividades	17
	17
	18
2. En cada organización, seleccionar por conveniencia una muestra de 40 lotes documentales (conjuntos de al menos 10 documentos variados) que representen la carga de trabajo real. Para cada lote, realizar las siguientes mediciones en las condiciones habituales del proceso manual	18
3. Todos los datos del pretest se tabulan en la matriz MD-01 y se almacenan en repositorio controlado.	18
4. Instalar en los equipos designados el software del ecosistema -compuesto por los módulos de captura TWAIN/WIA, OCR con inteligencia artificial local, motor de clasificación basado en áreas, códigos y tipos documentales, y motor de cifrado automático- configurando las rutas de carpetas vigiladas, las cuentas de sincronización (Google Drive o Dropbox) y las listas de palabras/oraciones llave para el cifrado.	18
5. Realizar una capacitación de dos horas a los operadores participantes sobre el uso del sistema, haciendo hincapié en el manejo de la carpeta de pendientes y en la revisión de los logs inmutables que se generan automáticamente.	18
6. Ejecutar una prueba piloto con 10 documentos para verificar la estabilidad del entorno y ajustar parámetros de reconocimiento.	18

7. Durante un período de cuatro semanas, cada lote documental que ingrese por escáner o carpeta vigilada será procesado exclusivamente con el ecosistema implementado. Se respetan las mismas condiciones operativas de volumen y tipo de documentos que en el pretest. Los usuarios operan en sesiones manuales, atendiendo la carpeta de pendientes cuando el sistema no reconoce automáticamente un documento, y cierran la sesión para disparar la sincronización cifrada. 19

8. El investigador monitorea remotamente los logs inmutables, recopilando en tiempo real los eventos de cada operación. 19

9. Al término del período de tratamiento, se repiten las mediciones de los incisos 2a-2e sobre los mismos indicadores, pero ahora capturados a partir de los logs del ecosistema y de observación directa del entorno de producción. Los tiempos se extraen del registro de marcas temporales de inicio y fin contenidos en los logs; la precisión de clasificación se calcula comparando la categoría asignada por el sistema con la validación manual del investigador; el porcentaje de documentos cifrados y los falsos positivos/negativos se computan con los registros de eventos del motor de cifrado; y la completitud de logs se evalúa verificando que cada actividad prevista esté documentada. 19

10. Los datos se consolidan en la misma matriz MD-01, distinguiendo la condición "pretest" y "postest". 19

4.3 Materiales e instrumentos 19

1. Plantilla de registro de tiempo por documento (TR-01): hoja de cálculo en la que se anotan, para cada lote, la hora de inicio del escaneo, la hora de finalización del almacenamiento y el número de documentos procesados. A partir de ella se calcula el tiempo promedio por documento. La captura en el pretest es manual (cronómetro); en el postest, el dato se toma automáticamente del campo timestamp de los logs del sistema, complementado con verificación manual de una submuestra del 20 %. 20

2. Matriz de verificación de clasificación (MC-01): tabla que contiene el identificador del documento, la categoría real (según metadatos originales), la categoría asignada por el proceso manual o por el sistema, y una columna de acierto (1 = correcto, 0 = incorrecto). Con ella se computa la precisión de clasificación como aciertos totales / total documentos. 20

3. Lista de verificación de cifrado (LC-01): por cada documento, se consigna si contiene información sensible (definida por al menos una de ocho palabras u oraciones llave, como "confidencial", "datos personales", "número de identificación", etc.) y si el archivo resultante fue cifrado (verificación mediante intento de apertura sin la clave adecuada). El porcentaje de documentos sensibles cifrados se calcula como (documentos sensibles cifrados / total documentos sensibles) x 100. 20

4. Registro de falsos positivos y negativos (RFN-01): matriz que contrasta la predicción del sistema con la condición real de sensibilidad. Falso positivo: documento no sensible que fue cifrado; falso negativo: documento sensible que no fue cifrado. Ambas cifras se totalizan y se expresan como porcentaje del total de documentos procesados. 20

5. Protocolo de análisis de logs (PAL-01): script en Python que lee los logs inmutables del ecosistema y contabiliza la cantidad de eventos esperados (inicio de sesión, captura, OCR, clasificación, cifrado, sincronización, cierre) frente a los eventos registrados, calculando la completitud como (eventos registrados / eventos esperados) x 100. Además, detecta errores de sincronización (fallos en la transferencia a la nube) y los suma para obtener el indicador de errores de sincronización (cantidad por lote). 20

4.4 Población y muestra 21

4.5 Técnicas de procesamiento y análisis de datos 21

1. Eficiencia (tiempo promedio por documento): se plantea la hipótesis H1: existe diferencia significativa entre el tiempo promedio antes y después de la implementación. Se empleará la prueba t de Student para muestras relacionadas si se cumple la normalidad; en su defecto, la prueba de rangos con signo de Wilcoxon. Se usará un nivel de significancia $\alpha = 0.05$ y se reportará el valor p bilateral. El tamaño del efecto se medirá con la d de Cohen ($d = \text{diferencia de medias} / \text{desviación estándar de las diferencias}$). 22

2. Precisión de clasificación: análogamente, la diferencia entre la proporción de aciertos en el pretest y el posttest se evaluará con la misma prueba t apareada (o Wilcoxon). Se complementará con la comparación de tasas mediante la prueba de McNemar si se transforma la variable a dicotómica por lote (p. ej., "lote completamente correcto" vs. "con al menos un error"), aportando robustez. 22

3. Porcentaje de documentos sensibles cifrados y métricas de falsos positivos/negativos: dado que estas variables son proporciones calculadas sobre 120 lotes, se compararán las medias con t de Student apareada (si la muestra es grande es robusta a la no normalidad). Adicionalmente, para la proporción de documentos cifrados, se construirá una tabla de contingencia 2x2 (pretest/posttest x cifrado/no cifrado) por documento, y se aplicará la prueba Q de Cochran para cada lote o una prueba de chi-cuadrado de McNemar a nivel global, a fin de evaluar la homogeneidad marginal. 22

4. Completitud de logs: la diferencia entre el índice de completitud antes (cercano a cero por la inexistencia de logs específicos) y después se someterá a la prueba t apareada (o Wilcoxon). Se espera un incremento significativo. 22

5. Errores de sincronización: en el pretest este indicador se mide de manera aproximada contando fallos en la copia manual a dispositivos externos; en el posttest se contabilizan los errores reportados por el sistema. Se compararán las medias con la prueba adecuada, aunque se prevé una reducción drástica. 22

V. ASPECTOS ADMINISTRATIVOS 23

5.1 Cronograma de actividades 23

5.2 Recursos humanos 24

5.3 Presupuesto y financiamiento 24

VI. REFERENCIAS BIBLIOGRÁFICAS 25

I. DATOS GENERALES

1.1 Título

Ecosistema de gestión documental inteligente, clasificación autónoma y ciberseguridad para organizaciones de servicios de Tacna, 2026

1.2 Área de investigación

Ingeniería de Sistemas / Ingeniería de Software

1.3 Línea de investigación

Sistemas de información, transformación digital y gestión documental inteligente

1.4 Autor(es)

Bach. Ahmed Hasan Akhtar Oviedo Bach. Carlos Daniel Ayala Ramos

1.5 Asesor

Ing. Luis Alfredo Fernández Vizcarra

Nota de consistencia del título: El título identifica la variable independiente (ecosistema de gestión documental inteligente que integra componentes de clasificación autónoma y ciberseguridad), la unidad de análisis implícita (documentos administrativos de organizaciones de servicios), el ámbito espacial (Tacna) y el horizonte temporal de ejecución (2026). Mantiene correspondencia con los indicadores de eficiencia, precisión y seguridad que se operacionalizarán en la matriz de consistencia.

II. EL PROBLEMA DE INVESTIGACIÓN

2.1 Descripción del problema

Las organizaciones de servicios públicas y privadas en Tacna gestionan diariamente un volumen considerable de documentos administrativos que nacen, circulan y se archivan mayoritariamente en soporte físico. Si bien muchas de estas entidades disponen de escáneres y generan representaciones digitales de los documentos, carecen de procesos estandarizados y automatizados que integren la captura, la clasificación, el cifrado y el respaldo de la información sensible. La práctica habitual consiste en operar el escáner de forma aislada, asignar nombres de archivo manualmente, organizar los documentos en carpetas según criterios personales y, en el mejor de los casos, realizar copias esporádicas en dispositivos externos. Esta cadena de trabajo manual introduce múltiples puntos de fricción que afectan la eficiencia, la confiabilidad y la seguridad de la información institucional.

El impacto inmediato de este esquema manual se traduce en demoras y errores de clasificación. Los operadores deben leer cada documento, interpretar su tipología y decidir un destino dentro de la estructura de carpetas, tarea propensa a inconsistencias cuando intervienen varios usuarios o cuando la carga de trabajo es alta. Con frecuencia, documentos de naturaleza sensible -contratos, informes con datos personales, expedientes de recursos humanos- se almacenan sin cifrado alguno o se archivan en ubicaciones erróneas, quedando expuestos a accesos no autorizados. La falta de un mecanismo automático de detección de datos sensibles y la ausencia de cifrado en origen contravienen, además, las disposiciones de la Ley N.º 29733, Ley de Protección de Datos Personales, generando un riesgo jurídico para las organizaciones.

Otro efecto adverso relevante es la pérdida de trazabilidad. Los procedimientos actuales no generan registros íntegros e inmutables de quién capturó un documento, cuándo fue modificado, qué criterios se utilizaron para clasificarlo o si fue compartido con terceros. En caso de auditorías internas o externas, reconstruir la historia de un documento se convierte en una labor reconstructiva, lenta y subjetiva, que erosiona la transparencia organizacional. Paralelamente, la sincronización de los

documentos digitalizados con repositorios en la nube, cuando existe, depende de la voluntad y el tiempo del operador, de modo que no es raro hallar versiones desactualizadas o incompletas, lo que incrementa la probabilidad de pérdida de información ante fallos locales.

La situación descrita revela una brecha entre la capacidad tecnológica disponible -escaneres modernos, conectividad, soluciones de IA accesibles- y la adopción efectiva de un flujo documental automatizado que contemple desde la captura hasta el respaldo cifrado. Las organizaciones de servicios en Tacna, especialmente aquellas de tamaño mediano y pequeño, no han implementado ecosistemas que integren OCR local, clasificación autónoma mediante reconocimiento de patrones textuales, cifrado dinámico basado en palabras clave y sincronización automática al cierre de sesión. Esta carencia perpetúa procesos manuales que, en conjunto, reducen la productividad, incrementan los costos operativos y debilitan la postura de seguridad de la información.

En este contexto, la presente investigación se propone implementar un ecosistema de gestión documental inteligente que articule captura por escáner TWAIN/WIA o carpeta vigilada, OCR e IA local para reconocimiento de códigos, áreas y disciplinas, renombrado automático, carpeta de pendientes para documentos no reconocidos, cifrado automático de PDF mediante oraciones llave, respaldo sincronizado a Google Drive o Dropbox al cerrar sesión y generación de logs inmutables. El estudio evaluará, en un entorno preexperimental, el efecto de dicho ecosistema sobre la eficiencia y la seguridad documental, aportando evidencia empírica para la adopción de buenas prácticas en el ámbito local.

2.2 Formulación del problema

Problema general ¿En qué medida la implementación de un ecosistema de gestión documental inteligente, con clasificación autónoma y ciberseguridad, mejora la eficiencia y la seguridad en la gestión documental de las organizaciones de servicios de Tacna, 2026?

Problemas específicos

- PE1: ¿Cuál es el efecto del ecosistema sobre el tiempo promedio de procesamiento por documento administrativo?
- PE2: ¿En qué medida la clasificación autónoma mejora la precisión de la clasificación documental en comparación con el proceso manual?
- PE3: ¿Qué porcentaje de documentos sensibles son cifrados automáticamente por el ecosistema frente al cifrado manual previo?
- PE4: ¿Cómo influye el ecosistema en la completitud e integridad de los logs de auditoría respecto al procedimiento manual?
- PE5: ¿Cuál es el impacto del ecosistema sobre la tasa de errores en la sincronización de documentos con los repositorios en la nube?

2.3 Justificación e importancia

La investigación se justifica desde una perspectiva práctica por la necesidad urgente de las organizaciones de servicios de Tacna de incrementar la productividad y fortalecer la protección de sus activos de información. La automatización del flujo documental mediante un ecosistema integrado permite reducir drásticamente los tiempos de búsqueda, los errores de archivo y la repetición de tareas, liberando horas de trabajo que pueden destinarse a labores de mayor valor añadido. Al mismo tiempo, el cifrado automático de los documentos que contienen datos sensibles y la generación de registros de auditoría inalterables facilitan el cumplimiento normativo y reducen la probabilidad de sanciones administrativas.

Desde el punto de vista teórico, el estudio contribuye a la literatura sobre sistemas de gestión documental inteligente al operacionalizar constructos de clasificación autónoma y cifrado dinámico en un entorno real acotado. Se validará un instrumento de medición que articula indicadores de eficiencia

operativa y de seguridad, generando evidencia sobre el comportamiento conjunto de variables como precisión de IA local, integridad de logs y tasa de sincronización. Los resultados podrán servir de referencia para futuras investigaciones que busquen replicar o escalar este tipo de ecosistemas en contextos organizacionales similares.

En el ámbito social, la mejora en la gestión documental tiene un impacto directo en la calidad del servicio que las entidades públicas y privadas ofrecen a los ciudadanos. Una respuesta más rápida a las solicitudes de información, una custodia más fiable de los datos personales y una mayor transparencia en la administración de los documentos fortalecen la confianza de la población en las instituciones. Asimismo, al estandarizar procesos de seguridad de la información, se protegen derechos fundamentales de las personas, alineando la operación cotidiana con los principios de la Ley de Protección de Datos Personales.

Económicamente, el proyecto se justifica por el ahorro sustancial que supone la reducción del tiempo-hombre dedicado a la clasificación, el archivo y la recuperación de documentos. La disminución de pérdidas de información por extravíos o accesos indebidos evita costos asociados a la reconstrucción de documentos y a eventuales indemnizaciones. La arquitectura del ecosistema planteado, basada en componentes de código abierto y en el aprovechamiento de infraestructura existente, ofrece una relación costo-beneficio favorable para organizaciones de tamaño medio, eliminando dependencias de licencias onerosas y facilitando su adopción en el mercado local.

Por último, desde la perspectiva de la seguridad de la información, la incorporación de cifrado automático vinculado a palabras clave sensibles, la sincronización inmediata al cierre de sesión y la generación de logs inmutables configuran una mejora sustancial en la protección de la confidencialidad, integridad y disponibilidad de los documentos. El estudio aportará indicadores concretos sobre la efectividad de estos mecanismos, ofreciendo un modelo replicable que neutralice las principales amenazas internas y externas a las que se enfrentan las organizaciones de servicios en el contexto actual.

2.4 Objetivos

Objetivo general Determinar en qué medida la implementación de un ecosistema de gestión documental inteligente, con clasificación autónoma y ciberseguridad, mejora la eficiencia y la seguridad en la gestión documental de las organizaciones de servicios de Tacna, 2026.

Objetivos específicos

- OE1: Medir el tiempo promedio de procesamiento por documento administrativo antes y después de la implementación del ecosistema.
- OE2: Evaluar la mejora en la precisión de la clasificación documental al emplear el sistema de clasificación autónoma respecto al método manual.
- OE3: Cuantificar el porcentaje de documentos sensibles que son cifrados automáticamente por el ecosistema en contraste con el procedimiento manual previo.
- OE4: Analizar la completitud e integridad de los logs de auditoría generados por el ecosistema frente a los registros manuales.
- OE5: Comparar la tasa de errores de sincronización con los repositorios en la nube antes y después de la adopción del ecosistema.

2.5 Hipótesis

La presente investigación adopta un enfoque cuantitativo y un diseño preexperimental, condiciones que hacen pertinente la formulación de hipótesis de diferencia de medias o proporciones. A continuación, se plantean las hipótesis de trabajo (Hi) contrastadas con sus respectivas hipótesis nulas (H0).

Hipótesis general Hi: La implementación del ecosistema de gestión documental inteligente mejora significativamente la eficiencia y la seguridad en la gestión documental de las organizaciones de servicios de Tacna, 2026. H0: La implementación del ecosistema no produce una mejora significativa en la eficiencia y la seguridad documental.

Hipótesis específicas

- H1: El tiempo promedio de procesamiento por documento administrativo es significativamente menor después de la implementación del ecosistema.

H01: El tiempo promedio de procesamiento no difiere significativamente antes y después de la implementación.

- H2: La precisión de la clasificación autónoma es significativamente mayor que la obtenida mediante el proceso manual.

H02: La precisión de la clasificación autónoma no supera significativamente la del método manual.

- H3: El porcentaje de documentos sensibles cifrados automáticamente es significativamente superior al porcentaje alcanzado en el procedimiento manual.

H03: La proporción de documentos sensibles cifrados no difiere significativamente entre el ecosistema y el método manual.

- H4: La completitud de los logs de auditoría generados por el ecosistema es significativamente mayor que la de los registros manuales.

H04: La completitud de los logs no presenta una diferencia significativa entre ambos procedimientos.

- H5: La tasa de errores de sincronización con los repositorios en la nube es significativamente menor tras la implantación del ecosistema.

H05: La tasa de errores de sincronización no varía significativamente antes y después de la implantación.

2.6 Tipo y nivel de investigación

El presente estudio se clasifica como **investigación aplicada**, en tanto persigue la solución de un problema práctico concreto -la ineficiencia e inseguridad en la gestión documental de las organizaciones de servicios- mediante la implementación y evaluación de una solución tecnológica específica. Se enmarca en el paradigma cuantitativo, ya que los objetivos requieren la recolección de datos numéricos sobre tiempos, tasas de precisión, proporciones de cifrado e integridad de registros, los cuales serán sometidos a análisis estadístico para contrastar las hipótesis planteadas.

El **nivel de investigación es explicativo**, porque no solo se limita a describir las variables implicadas, sino que busca establecer relaciones de causalidad entre la variable independiente -el ecosistema de gestión documental inteligente- y las variables dependientes -eficiencia y seguridad-, controlando el efecto de factores externos mediante un diseño preexperimental de un solo grupo con preprueba y posprueba. La observación de las métricas antes y después de la intervención permitirá inferir el impacto neto del ecosistema sobre los indicadores definidos.

El **diseño** corresponde a un preexperimento de tipo antes-después (O1 - X - O2), donde O1 representa la medición de los indicadores bajo el proceso manual actual, X es la implementación del ecosistema y O2 la medición posterior sobre la misma muestra de documentos y usuarios. La validez interna se refuerza al emplear un mismo lote de documentos administrativos, iguales condiciones de hardware y un período acotado de recolección, reduciendo la influencia de variables extrañas. Esta estrategia resulta adecuada para contextos organizacionales medianos, donde la asignación aleatoria de grupos resulta inviable, pero se requiere evidencia inicial sólida sobre la efectividad de la solución propuesta.

2.7 OPERACIONALIZACIÓN DE VARIABLES

La contrastación empírica de las hipótesis exige descomponer las variables del estudio en definiciones conceptuales, operacionales, dimensiones e indicadores susceptibles de medición, todo ello alineado con el diseño pre-experimental y las técnicas cuantitativas propuestas. La Tabla 1 sistematiza dicha operacionalización, identificando la variable independiente que será manipulada y las variables dependientes que reflejan los cambios esperados en eficiencia, precisión, seguridad y trazabilidad.

Tabla 1 Matriz de operacionalización de variables

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala de medición	Técnica/método de recolección	Instrumento/fuente
Variable independiente (VI): Ecosistema de gestión documental inteligente con clasificación autónoma y ciberseguridad	Sistema informático que integra captura normalizada (TWAIN/WIA), reconocimiento óptico de caracteres (OCR), clasificación automática por inteligencia artificial, cifrado condicional de archivos PDF y sincronización a nube, generando registros inmutables de auditoría (basado en ISO 15489-1:2016 y Ley N.º 29733).	Intervención dicotómica: durante la fase pre-test los documentos se procesan con el método manual tradicional; en la fase post-test se aplica el ecosistema completo. La manipulación se registra como 0 (sin sistema) y 1 (con sistema).	No aplica (variable de tratamiento)	Presencia/Ausencia del ecosistema	Nominal	Observación controlada del flujo de trabajo	Protocolo de implementación y configuración del ecosistema (checklist técnico)
Variable dependiente 1: Eficiencia del procesamiento documental	Rapidez con que se completa la secuencia digitalización-clasificación-cifrado-respaldo de un documento, expresada como tiempo total consumido por unidad documental.	Se medirá el lapso transcurrido desde la activación de la captura (escáner o carpeta vigilada) hasta el depósito del PDF cifrado en la carpeta de destino. Se registrará para cada uno de los 120 documentos de la muestra y se calculará el promedio por sesión.	Tiempos operativos	Tiempo promedio por documento (min:seg)	Razón	Observación sistemática mediante módulo de cronometría incorporado y análisis de logs temporales	Hoja de registro automatizada de tiempos; logs de inicio-fin de operación

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala de medición	Técnica/método de recolección	Instrumento/fuente
		Además se contabilizarán los fallos en la etapa de sincronización.	Fiabilidad de respaldo	Tasa de errores de sincronización (%)	Razón	Revisión de eventos del módulo de sincronización	Contador de eventos de error en el módulo Dropbox/Google Drive; archivo de excepciones
Variable dependiente 2: Precisión de clasificación documental	Grado de concordancia entre la categoría asignada por el motor de IA y la clasificación de referencia determinada por un panel experto, conforme a los tipos documentales predefinidos (facturas, contratos, informes, etc.).	Se comparará la etiqueta de salida del sistema con la etiqueta consensuada por dos especialistas en gestión documental sobre la totalidad de los 120 documentos. Los resultados se organizarán en una matriz de confusión.	Exactitud global	Precisión global de clasificación (%)	Razón	Prueba de rendimiento y validación inter-jueces	Matriz de confusión; planilla de evaluación de expertos; registros de decisión del motor de IA
		Se identificarán los errores por exceso y por omisión.	Control de errores	Tasa de falsos positivos (%)	Razón	Análisis de celdas de la matriz de confusión	Matriz de confusión; script de discrepancia con el gold standard
			Control de errores	Tasa de falsos negativos (%)	Razón	Análisis de celdas de la matriz de confusión	Matriz de confusión; script de discrepancia con el gold standard

Variable	Definición conceptual	Definición operacional	Dimensiones	Indicadores	Escala de medición	Técnica/método de recolección	Instrumento/fuente
Variable dependiente 3: Nivel de ciberseguridad del documento	Cobertura del mecanismo de protección de la información sensible mediante cifrado automático de archivos PDF que contengan palabras u oraciones llave definidas (p. ej., datos personales, bancarios).	Sobre un subconjunto de 50 documentos que incluye 20 con contenido sensible validado, se verificará binariamente si cada uno fue cifrado (AES-256) por el sistema. El indicador será el cociente entre documentos sensibles cifrados y el total de documentos sensibles.	Cobertura de cifrado	Porcentaje de documentos sensibles cifrados (%)	Razón	Inspección de propiedades de seguridad de cada archivo y cruce con el registro de cifrado	Script verificador de metadatos y estructura PDF; logs de cifrado del sistema
Variable dependiente 4: Integridad de trazabilidad	Complejidad de los registros de auditoría generados automáticamente, entendida como la presencia de todos los campos obligatorios (ID único, estampa de tiempo, tipo de operación, usuario, hash SHA-256 del archivo) en cada entrada log.	Se examinarán los logs correspondientes a los 120 documentos procesados en la fase post-test. Se considerará un log completo si contiene la totalidad de los campos; incompleto si falta al menos uno. El indicador es el porcentaje de logs completos respecto del total.	Complejidad estructural del log	Porcentaje de logs completos (%)	Razón	Análisis documental automatizado de los archivos de auditoría	Plantilla de verificación de campos del log; programa de validación de esquema JSON/CSV
		Adicionalmente se verificará la inmutabilidad calculando el hash de cada log y comparándolo con el hash registrado.	Inmutabilidad	Coincidencia del hash de integridad (Sí/No)	Nominal	Verificación criptográfica de cadena	Función de verificación de hash en la base de logs

Nota. La validez de contenido de los instrumentos será sometida a juicio de tres expertos en ingeniería de software y seguridad de la información. La confiabilidad se estimará mediante una prueba piloto con 20 documentos que no formarán parte de la muestra definitiva, calculando el coeficiente alfa de

Cronbach para escalas de razón compuestas y el índice Kappa de Cohen para la clasificación categórica.

III. MARCO TEÓRICO

El marco teórico que se presenta a continuación sustenta conceptual y empíricamente la investigación, estructurándose en tres componentes fundamentales: antecedentes de estudios previos, bases teóricas que desarrollan los constructos centrales y definición de términos técnicos que operacionalizan el ecosistema propuesto.

3.1 Antecedentes de la investigación

La transformación digital de los procesos documentales ha sido abordada desde múltiples ángulos en la literatura reciente. A nivel internacional, se reconoce que la adopción de tecnologías de captura, reconocimiento óptico de caracteres (OCR) y almacenamiento en la nube ha mejorado la eficiencia en organizaciones de servicios, aunque persisten desafíos en la estandarización de flujos de trabajo y en la protección de datos sensibles. Los estudios pioneros se centraron en la digitalización masiva de archivos históricos, evidenciando que la ausencia de metadatos estructurados y de mecanismos automáticos de clasificación limitaba la recuperación posterior de información (Universidad Privada de Tacna, Facultad de Ingeniería, 2022).

En el ámbito de la clasificación documental automatizada, diversas investigaciones han explorado la aplicación de técnicas de aprendizaje automático sobre documentos administrativos. Se ha reportado que modelos entrenados con corpus locales pueden alcanzar precisiones superiores al 85 % en la categorización de facturas, órdenes de compra y correspondencia institucional, siempre que el OCR haya extraído correctamente los campos de texto relevantes. No obstante, la mayoría de estos trabajos se ejecutó en entornos controlados sin flujo continuo de documentos ni integración con escáneres en tiempo real, lo que deja una brecha para soluciones que operen directamente desde la captura.

Respecto a la ciberseguridad documental, la Ley de Protección de Datos Personales del Perú (Ley N.º 29733) establece la obligación de resguardar la información sensible mediante medidas técnicas y organizativas adecuadas. Estudios aplicados en empresas de servicios han demostrado que el cifrado automático de archivos PDF, basado en detección de palabras clave, reduce significativamente el riesgo de exposición de datos personales durante el almacenamiento y la transferencia. Sin embargo, la implementación de estos mecanismos suele ser reactiva y no está integrada en una cadena continua de captura-clasificación-respaldo.

En cuanto a trazabilidad y registros de auditoría, el estándar ISO 15489-1:2016 (International Organization for Standardization, 2016) enfatiza la necesidad de mantener metadatos que documenten el ciclo de vida de los documentos. Investigaciones recientes sobre sistemas de información gubernamentales han mostrado que la incorporación de logs inmutables, basados en técnicas de *hashing* encadenado, fortalece la integridad de las evidencias y facilita auditorías externas. Esos hallazgos son extrapolables al contexto de las organizaciones de servicios en Tacna, donde la rendición de cuentas y la transparencia constituyen demandas crecientes.

Finalmente, aunque no específicas sobre gestión documental, algunas referencias ofrecen marcos conceptuales pertinentes que requieren verificación de contenido completo para establecer su aplicabilidad directa. Masó Pau y Pons Fernández (2025) analizaron los principios FAIR en datos generados por la ciudadanía, lo que resalta la importancia de la localización y accesibilidad de los recursos digitales, principios aplicables a un repositorio documental cifrado. Alderete (2021) examinó determinantes de la apertura de datos a nivel de países, subrayando la relevancia de políticas institucionales para el acceso seguro a la información; su extensión al ámbito organizacional local podría enriquecer el análisis, aunque la referencia debe ser validada en texto completo. Guillén Henríquez y Toledo Santos (2019) describieron la implementación de asignaturas de informática en secundaria, lo que indirectamente evidencia la necesidad de competencias digitales en los operadores de sistemas documentales. Ninguna de estas fuentes ha sido confirmada en cuanto a resultados

específicos, por lo que se consignan como referencias candidatas para verificación antes de su inclusión definitiva.

3.2 Bases teóricas

A continuación se exponen los fundamentos conceptuales que sustentan cada uno de los componentes del ecosistema de gestión documental inteligente, clasificación autónoma y ciberseguridad.

3.2.1 Gestión documental y digitalización

La gestión documental se define como el conjunto de procesos sistemáticos orientados a la creación, organización, almacenamiento, recuperación y disposición final de los documentos, con el fin de garantizar su disponibilidad, autenticidad y fiabilidad (ISO 15489-1, 2016). En el contexto de las organizaciones de servicios, la digitalización constituye el primer eslabón de esa cadena, transformando documentos físicos en representaciones digitales mediante escáneres. La norma TWAIN/WIA estandariza la comunicación entre dispositivos de captura y aplicaciones de software, permitiendo la adquisición directa de imágenes sin intervención manual compleja. Un proceso de digitalización objetivo requiere definir parámetros de resolución, formato de archivo (PDF, TIFF) y compresión, para obtener documentos legibles y con tamaño manejable.

3.2.2 Clasificación autónoma con inteligencia artificial

La clasificación documental asistida por inteligencia artificial (IA) emplea algoritmos de aprendizaje automático para asignar categorías predefinidas a un documento a partir de su contenido textual. En el ecosistema propuesto, tras la extracción de texto mediante OCR, un modelo de procesamiento de lenguaje natural (PLN) analiza la presencia de códigos, términos clave y patrones sintácticos que indiquen áreas, disciplinas y tipos documentales (factura, contrato, informe, etc.). Técnicas como las máquinas de soporte vectorial (SVM), los árboles de decisión o las redes neuronales recurrentes han mostrado eficacia en este dominio. La clasificación se complementa con un mecanismo de "carpeta vigilada" para aquellos documentos cuyo contenido no alcance un umbral mínimo de confianza, los cuales son derivados a una bandeja de pendientes para revisión manual, cerrando así el ciclo de aprendizaje supervisado que permite la mejora continua del modelo.

3.2.3 Ciberseguridad documental: cifrado y protección de datos sensibles

La ciberseguridad documental busca preservar la confidencialidad, integridad y disponibilidad de la información contenida en los documentos digitales. El cifrado automático de archivos PDF se implementa mediante algoritmos simétricos (p. ej., AES-256) activados por la detección de palabras u oraciones llave que indican la presencia de datos sensibles (nombres, DNI, datos bancarios). El estándar PDF 2.0 admite la inclusión de mecanismos de protección por contraseña y de permisos diferenciados (lectura, impresión, modificación). En el ecosistema, la prioridad de la oración llave se utiliza para resolver empates cuando un documento contiene múltiples indicios de sensibilidad, asegurando que se aplique la política más restrictiva. Este enfoque proactivo reduce la exposición accidental y cumple con lo establecido en la Ley N.º 29733, que obliga al responsable del tratamiento de datos a implementar medidas de seguridad desde el diseño.

3.2.4 Logs inmutables y trazabilidad

Un log inmutable es un registro cronológico de eventos del sistema que no puede ser modificado ni eliminado una vez escrito. En el ecosistema propuesto, cada operación significativa (escaneo, clasificación, cifrado, sincronización) genera una entrada de log con un identificador único, una marca de tiempo y una función hash que vincula la entrada con la anterior, formando una cadena de integridad. Este mecanismo, inspirado en la tecnología de cadenas de bloques ligeras, facilita auditorías completas y permite reconstruir la trazabilidad de cada documento, desde su ingreso hasta su almacenamiento final. La trazabilidad es esencial para garantizar la rendición de cuentas y para detectar accesos no autorizados o manipulaciones indebidas.

3.2.5 Sincronización en la nube

La sincronización con plataformas de almacenamiento en la nube como Google Drive o Dropbox extiende la accesibilidad de los documentos y proporciona una capa adicional de respaldo. El ecosistema ejecuta la sincronización al cierre de cada sesión de captura, asegurando que todos los documentos procesados y cifrados queden disponibles en un repositorio remoto. Este proceso debe ser robusto ante interrupciones de red y mantener la integridad mediante la verificación de sumas de comprobación. La elección de servicios de nube de amplia aceptación se fundamenta en su disponibilidad, escalabilidad y en las facilidades de control de acceso que ofrecen.

3.2.6 Normas de citación de tablas, figuras y ecuaciones

Con el propósito de mantener la rigurosidad académica, en todo el documento se seguirán las normas de la American Psychological Association en su séptima edición (APA 7.^a ed.) para la presentación de tablas, figuras y ecuaciones, conforme lo estipula el Manual para el desarrollo de trabajos de investigación de la FAING (2022). Las tablas se identificarán con la palabra "Tabla" y un número arábigo en negrita, seguidas de un título en cursiva. Las figuras llevarán la palabra "Figura" y número en negrita, con título en cursiva. Las ecuaciones se numerarán consecutivamente entre paréntesis, alineadas a la derecha. Toda tabla, figura o ecuación ajena debe ir acompañada de la nota de copyright o la referencia apropiada.

3.3 Definición de términos

Para facilitar la comprensión de los conceptos centrales del estudio, se presentan las siguientes definiciones operativas:

3.3.1 Ecosistema de gestión documental inteligente

Conjunto integrado de hardware (escáneres), software (captura, OCR, clasificación IA, cifrado, sincronización) y procedimientos que automatizan el ciclo de vida de los documentos administrativos, desde su digitalización hasta su almacenamiento seguro y respaldo en la nube.

3.3.2 Clasificación autónoma

Proceso mediante el cual un sistema basado en inteligencia artificial asigna una categoría predefinida a un documento sin intervención humana, utilizando el texto extraído por OCR y modelos de aprendizaje automático entrenados con ejemplos locales.

3.3.3 OCR (reconocimiento óptico de caracteres)

Tecnología que convierte imágenes de texto impreso o manuscrito en caracteres digitales editables y buscables, habilitando el análisis automático del contenido documental.

3.3.4 Cifrado de PDF

Aplicación de un algoritmo criptográfico al archivo PDF, activada por la detección de palabras u oraciones llave que señalan contenido sensible. El resultado es un documento legible únicamente por quien posea la clave o credenciales de acceso autorizadas.

3.3.5 Logs inmutables

Registros secuenciales de eventos del sistema protegidos mediante hashes encadenados, de modo que cualquier intento de alteración sea detectable, garantizando la trazabilidad y la integridad de la bitácora operativa.

3.3.6 Trazabilidad

Capacidad de reconstruir el historial completo de un documento, desde su captura hasta su disposición final, incluyendo todas las operaciones intermedias y los usuarios que participaron en cada etapa.

3.3.7 Sincronización en la nube

Proceso automatizado que transfiere los documentos procesados y cifrados a un servicio de almacenamiento remoto (Google Drive, Dropbox) al finalizar una sesión de trabajo, manteniendo una copia actualizada y accesible.

3.3.8 Documento administrativo

Cualquier soporte que contenga información generada o recibida por una organización de servicios en el ejercicio de sus funciones (oficios, informes, comprobantes, contratos, etc.), susceptible de digitalización.

3.3.9 Falsos positivos/negativos en clasificación

En el contexto del modelo de clasificación autónoma, se denomina falso positivo a la asignación incorrecta de una categoría a un documento que no le corresponde, y falso negativo cuando el sistema omite asignar la categoría correcta a un documento que sí pertenece a ella. Ambos indicadores afectan la precisión global del sistema.

3.3.10 Sesiones de captura

Período de operación en el que el usuario interactúa con el escáner o la carpeta vigilada, los documentos son digitalizados y procesados, y al finalizar se activa la sincronización. Cada sesión delimita un lote de trabajo y facilita la consolidación de logs y métricas.

IV. MARCO METODOLÓGICO

4.1 Diseño de investigación

La investigación se enmarca como aplicada, de enfoque cuantitativo y alcance explicativo, puesto que se interviene deliberadamente un proceso real con el propósito de medir cambios en indicadores de eficiencia, precisión, seguridad y trazabilidad. Se adopta un diseño pre-experimental de un solo grupo con pretest y posttest (O1 - X - O2), en el cual la observación O1 registra la situación actual del proceso manual, X consiste en la implementación y uso del ecosistema de gestión documental inteligente con clasificación autónoma y ciberseguridad, y O2 captura los mismos indicadores después de la intervención, sobre la misma muestra documental. La ausencia de grupo de control es aceptable en este nivel de investigación aplicada, ya que el objetivo es verificar la efectividad de la solución tecnológica en un contexto real, controlando las características de los documentos y los procedimientos operativos. Los datos se recogen en un único momento temporal antes y un único momento después, sin manipular otras variables del entorno organizacional, manteniendo constante el hardware de escaneo y las rutinas administrativas.

4.2 Acciones y actividades

El procedimiento experimental se organiza en cuatro fases, cuyas actividades concretas se detallan a continuación.

Fase 1. Selección de organizaciones y establecimiento de línea base (pretest)

1. Identificar, mediante convocatoria abierta o carta de invitación, tres organizaciones de servicios de Tacna -públicas o privadas- que cumplan los siguientes criterios de inclusión: (a) gestionar diariamente documentos administrativos en soporte físico que requieran digitalización; (b) disponer de escáneres compatibles con TWAIN o WIA y de equipos con sistema operativo Windows 10/11; (c)

no poseer un sistema automatizado de clasificación ni cifrado de documentos; y (d) autorizar el acceso a los registros operativos bajo estrictas condiciones de confidencialidad y anonimización de datos personales.

2. En cada organización, seleccionar por conveniencia una muestra de 40 lotes documentales (conjuntos de al menos 10 documentos variados) que representen la carga de trabajo real. Para cada lote, realizar las siguientes mediciones en las condiciones habituales del proceso manual

a. Cronometrar el tiempo transcurrido desde que se inicia el escaneo hasta que todos los archivos quedan almacenados en la carpeta destino, usando un cronómetro digital y la plantilla de registro TR-01 (Anexo B). b. Solicitar al operador que clasifique manualmente los documentos y anotar la categoría asignada. El investigador contrastará cada clasificación con la que hubiera sido correcta según los metadatos reales del documento, para calcular la precisión inicial. c. Registrar la cantidad de documentos que contienen información sensible (definida por palabras clave establecidas en el protocolo de identificación) y verificar si fueron guardados con algún método de protección. Se anota un "sí" o "no" por cada documento. d. Contar los falsos positivos (documentos sin datos sensibles tratados como si los tuvieran) y los falsos negativos (documentos con datos sensibles no detectados), ambos con base en una lista de verificación predefinida. e. Obtener del sistema operativo los registros de eventos de archivo (logs nativos) para determinar si la trazabilidad actual es suficiente; se mide el porcentaje de operaciones documentadas frente al total de operaciones observadas.

3. Todos los datos del pretest se tabulan en la matriz MD-01 y se almacenan en repositorio controlado.

Fase 2. Implementación del ecosistema

4. Instalar en los equipos designados el software del ecosistema -compuesto por los módulos de captura TWAIN/WIA, OCR con inteligencia artificial local, motor de clasificación basado en áreas, códigos y tipos documentales, y motor de cifrado automático- configurando las rutas de carpetas vigiladas, las cuentas de sincronización (Google Drive o Dropbox) y las listas de palabras/oraciones llave para el cifrado.

5. Realizar una capacitación de dos horas a los operadores participantes sobre el uso del sistema, haciendo hincapié en el manejo de la carpeta de pendientes y en la revisión de los logs inmutables que se generan automáticamente.

6. Ejecutar una prueba piloto con 10 documentos para verificar la estabilidad del entorno y ajustar parámetros de reconocimiento.

Fase 3. Aplicación del tratamiento

7. Durante un período de cuatro semanas, cada lote documental que ingrese por escáner o carpeta vigilada será procesado exclusivamente con el ecosistema implementado. Se respetan las mismas condiciones operativas de volumen y tipo de documentos que en el pretest. Los usuarios operan en sesiones manuales, atendiendo la carpeta de pendientes cuando el sistema no reconoce automáticamente un documento, y cierran la sesión para disparar la sincronización cifrada.

8. El investigador monitorea remotamente los logs inmutables, recopilando en tiempo real los eventos de cada operación.

Fase 4. Recolección de posttest

9. Al término del período de tratamiento, se repiten las mediciones de los incisos 2a-2e sobre los mismos indicadores, pero ahora capturados a partir de los logs del ecosistema y de observación directa del entorno de producción. Los tiempos se extraen del registro de marcas temporales de inicio y fin contenidos en los logs; la precisión de clasificación se calcula comparando la categoría asignada por el sistema con la validación manual del investigador; el porcentaje de documentos cifrados y los falsos positivos/negativos se computan con los registros de eventos del motor de cifrado; y la completitud de logs se evalúa verificando que cada actividad prevista esté documentada.

10. Los datos se consolidan en la misma matriz MD-01, distinguiendo la condición "pretest" y "posttest".

4.3 Materiales e instrumentos

Materiales tecnológicos

- Escáneres con interfaz TWAIN o WIA (modelos presentes en las organizaciones, como HP ScanJet o Brother ADS, compatibles con el SDK del ecosistema).
- Computadoras con sistema operativo Windows 10/11, procesador Intel i5 o superior, 8 GB de RAM y al menos 50 GB de espacio libre para el procesamiento local.
- Conexión a Internet de banda ancha para la sincronización con Google Drive y Dropbox.
- Ecosistema de gestión documental inteligente desarrollado por los investigadores, que integra los módulos de captura, OCR (Tesseract con post-procesamiento basado en reglas lingüísticas), clasificación autónoma (red neuronal convolucional entrenada localmente sobre tipologías documentales peruanas), cifrado automático (AES-256) y generación de logs inmutables en cadena enlazada.
- Repositorio en la nube configurado con cuentas institucionales de las organizaciones participantes.

Instrumentos de recolección de datos Todos los instrumentos se alinean con la matriz de operacionalización de variables (Tabla 1, Sección 2.7) y permiten obtener las métricas antes y después. Se emplean cinco instrumentos específicos:

- 1. Plantilla de registro de tiempo por documento (TR-01):** hoja de cálculo en la que se anotan, para cada lote, la hora de inicio del escaneo, la hora de finalización del almacenamiento y el número de documentos procesados. A partir de ella se calcula el tiempo promedio por documento. La captura en el pretest es manual (cronómetro); en el postest, el dato se toma automáticamente del campo timestamp de los logs del sistema, complementado con verificación manual de una submuestra del 20 %.
- 2. Matriz de verificación de clasificación (MC-01):** tabla que contiene el identificador del documento, la categoría real (según metadatos originales), la categoría asignada por el proceso manual o por el sistema, y una columna de acierto (1 = correcto, 0 = incorrecto). Con ella se computa la precisión de clasificación como aciertos totales / total documentos.
- 3. Lista de verificación de cifrado (LC-01):** por cada documento, se consigna si contiene información sensible (definida por al menos una de ocho palabras u oraciones llave, como "confidencial", "datos personales", "número de identificación", etc.) y si el archivo resultante fue cifrado (verificación mediante intento de apertura sin la clave adecuada). El porcentaje de documentos sensibles cifrados se calcula como (documentos sensibles cifrados / total documentos sensibles) x 100.
- 4. Registro de falsos positivos y negativos (RFN-01):** matriz que contrasta la predicción del sistema con la condición real de sensibilidad. Falso positivo: documento no sensible que fue cifrado; falso negativo: documento sensible que no fue cifrado. Ambas cifras se totalizan y se expresan como porcentaje del total de documentos procesados.
- 5. Protocolo de análisis de logs (PAL-01):** script en Python que lee los logs inmutables del ecosistema y contabiliza la cantidad de eventos esperados (inicio de sesión, captura, OCR, clasificación, cifrado, sincronización, cierre) frente a los eventos registrados, calculando la completitud como (eventos registrados / eventos esperados) x 100. Además, detecta errores de sincronización (fallos en la transferencia a la nube) y los suma para obtener el indicador de errores de sincronización (cantidad por lote).

La validez de contenido de los instrumentos se asegurará mediante el juicio de tres expertos: un especialista en transformación digital documental, un ingeniero de software y un metodólogo. Se les

solicitará evaluar la pertinencia, claridad y suficiencia de los ítems de cada instrumento mediante una ficha de validación que emplea una escala dicotómica y el cálculo del coeficiente V de Aiken; se considerarán aceptables valores superiores a 0.80. La confiabilidad de la medición de tiempo y precisión obtenida a partir de los logs se evaluará comparando los registros automáticos con observaciones directas en un 20 % de los casos, determinando el índice de concordancia kappa.

4.4 Población y muestra

Población La población de estudio está constituida por el conjunto de lotes documentales diarios que generan todas las organizaciones de servicios (empresas de consultoría, estudios contables, notarías, oficinas públicas municipales, etc.) de la provincia de Tacna que cumplen con los criterios de inclusión descritos en 4.2. Por la naturaleza del fenómeno, se trata de una población infinita o de difícil conteo exacto, ya que no existe un registro censal de cada lote procesado.

Unidad de análisis La unidad de análisis es el lote documental, definido como un conjunto de entre 10 y 30 documentos administrativos en soporte físico que son escaneados y procesados en una misma sesión de trabajo por un operador. Cada lote genera mediciones de tiempo, precisión, cifrado y trazabilidad que constituyen los casos del estudio.

Muestra Dado el carácter aplicado y pre-experimental de la investigación, se utilizará un muestreo no probabilístico por cuotas. Se seleccionarán tres organizaciones representativas de la diversidad del sector servicios en Tacna: una mediana empresa privada (ej., estudio de abogados o contable), una entidad pública municipal (ej., unidad de trámite documentario) y una organización educativa de nivel superior que gestione expedientes académicos. En cada organización se tomará una cuota de 40 lotes documentales, totalizando 120 lotes observados ($n = 120$). Esta cifra excede el mínimo requerido para la aplicación de pruebas paramétricas en un diseño de medidas repetidas ($n > 30$) y permite un poder estadístico adecuado para detectar diferencias moderadas (d de Cohen = 0.5, $\alpha = 0.05$, poder 0.8). La selección de los lotes dentro de cada organización se hará por conveniencia, procurando cubrir distintos días de la semana y diferentes tipos de documentos para reflejar la variabilidad real.

Es importante aclarar que los operadores (entre 3 y 5 personas por organización) no constituyen la muestra, sino que son los ejecutores del proceso; sus características se registran para control, pero el análisis estadístico se centra en los 120 registros de lote.

Consideraciones éticas y de protección de datos Toda la información contenida en los documentos será anonimizada antes de su incorporación a la base de análisis: los números de identificación, nombres y datos de contacto serán reemplazados por tokens irreversibles, en cumplimiento de la Ley N.º 29733 de Protección de Datos Personales. Las organizaciones firmarán un consentimiento informado institucional, y los operadores recibirán una hoja de asentimiento que detalla el propósito exclusivamente investigativo de las observaciones. Los archivos cifrados durante la prueba no serán compartidos con terceros y se destruirán al finalizar el estudio.

4.5 Técnicas de procesamiento y análisis de datos

El análisis cuantitativo se realizará en dos niveles: descriptivo e inferencial, con apoyo de los paquetes estadísticos SPSS v.26 y Python (librerías pandas, scipy y statsmodels) para el procesamiento de los logs.

Análisis descriptivo Para cada indicador se calcularán medidas de tendencia central (media o mediana, según la distribución) y dispersión (desviación estándar, rango intercuartílico), tanto en la condición pretest como posttest. Se presentarán tablas de contingencia y gráficos de caja para comparar visualmente los cambios. La precisión de clasificación se expresará como proporción de aciertos; los falsos positivos y negativos como tasas; el porcentaje de documentos sensibles cifrados como porcentaje acumulado; y la completitud de logs como índice de 0 a 1.

Verificación de supuestos Antes de elegir la prueba de hipótesis, se comprobará la normalidad de las diferencias pretest-posttest de cada variable cuantitativa mediante la prueba de Shapiro-Wilk, considerando $n = 120$. Si $p > 0.05$, se asumirá distribución normal; en caso contrario, se aplicarán

pruebas no paramétricas.

Contraste de hipótesis

1. Eficiencia (tiempo promedio por documento): se plantea la hipótesis **H1: existe diferencia significativa entre el tiempo promedio antes y después de la implementación.** Se empleará la prueba t de Student para muestras relacionadas si se cumple la normalidad; en su defecto, la prueba de rangos con signo de Wilcoxon. Se usará un nivel de significancia $\alpha = 0.05$ y se reportará el valor p bilateral. El tamaño del efecto se medirá con la d de Cohen ($d = \text{diferencia de medias} / \text{desviación estándar de las diferencias}$).

2. Precisión de clasificación: análogamente, la diferencia entre la proporción de aciertos en el pretest y el posttest se evaluará con la misma prueba t apareada (o Wilcoxon). Se complementará con la comparación de tasas mediante la prueba de McNemar si se transforma la variable a dicotómica por lote (p. ej., "lote completamente correcto" vs. "con al menos un error"), aportando robustez.

3. Porcentaje de documentos sensibles cifrados y métricas de falsos positivos/negativos: dado que estas variables son proporciones calculadas sobre 120 lotes, se compararán las medias con t de Student apareada (si la muestra es grande es robusta a la no normalidad). Adicionalmente, para la proporción de documentos cifrados, se construirá una tabla de contingencia 2x2 (pretest/posttest x cifrado/no cifrado) por documento, y se aplicará la prueba Q de Cochran para cada lote o una prueba de chi-cuadrado de McNemar a nivel global, a fin de evaluar la homogeneidad marginal.

4. Completitud de logs: la diferencia entre el índice de completitud antes (cercano a cero por la inexistencia de logs específicos) y después se someterá a la prueba t apareada (o Wilcoxon). Se espera un incremento significativo.

5. Errores de sincronización: en el pretest este indicador se mide de manera aproximada contando fallos en la copia manual a dispositivos externos; en el posttest se contabilizan los errores reportados por el sistema. Se compararán las medias con la prueba adecuada, aunque se prevé una reducción drástica.

Todas las pruebas se ejecutarán con un nivel de confianza del 95 %. Para controlar la tasa de error por realizar múltiples contrastes sobre las mismas unidades, se aplicará la corrección de Bonferroni en las pruebas que involucren la misma familia de hipótesis (eficiencia, precisión y seguridad), ajustando el

nivel alfa dividido por el número de comparaciones.

Análisis complementario Se realizará un análisis de correlación de Pearson entre el número de documentos por lote y el tiempo de procesamiento, para descartar que la mejora se deba a diferencias en el volumen. Asimismo, se documentará el índice de concordancia entre los registros automáticos y las observaciones manuales (kappa) para validar la fiabilidad de los datos extraídos de los logs.

Toda la evidencia empírica recolectada permitirá aceptar o rechazar las hipótesis planteadas y cuantificar la magnitud de las mejoras atribuibles al ecosistema desarrollado.

V. ASPECTOS ADMINISTRATIVOS

5.1 Cronograma de actividades

Las actividades del proyecto se distribuyen en un horizonte de 12 meses, comenzando en enero de 2026 y finalizando con la sustentación en diciembre. La tabla 2 muestra el cronograma detallado.

Tabla 2 Cronograma de ejecución del plan de tesis

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8	Mes 9	Mes 10	Mes 11	Mes 12
Elaboración del plan de tesis (marco teórico, metodología)	■ ■	■ ■	■ ■									
Revisión de literatura y antecedentes	■ ■	■ ■										
Desarrollo del ecosistema (módulos de captura, OCR, IA, cifrado)		■ ■	■ ■	■ ■	■ ■	■ ■						
Pruebas de integración y ajustes del sistema					■ ■	■ ■						
Diseño de instrumentos y protocolo de recolección		■ ■	■ ■									

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8	Mes 9	Mes 10	Mes 11	Mes 12
Aplicación del pretest (proceso manual)							■ ■					
Implementación del ecosistema en entorno controlado							■ ■	■ ■				
Aplicación del posttest (uso del ecosistema)								■ ■	■ ■			
Procesamiento y análisis estadístico de datos									■ ■	■ ■		
Redacción del informe final										■ ■	■ ■	
Revisión por el asesor y levantamiento de observaciones											■ ■	
Sustentación												■ ■

5.2 Recursos humanos

Rol	Nombre	Función principal
Investigadores	Bach. Ahmed Hasan Akhtar Oviedo Bach. Carlos Daniel Ayala Ramos	Desarrollo del sistema, recolección de datos, análisis, redacción
Asesor	Ing. Luis Alfredo Fernández Vizcarra	Dirección metodológica y técnica, revisión del plan e informe final

5.3 Presupuesto y financiamiento

El proyecto será autofinanciado por los investigadores. El presupuesto estimado, cuyos montos son valores referenciales sujetos a confirmación, se desglosa a continuación.

Tabla 3 Presupuesto estimado del proyecto

Concepto	Descripción	Cantidad	Costo unitario (S/)	Costo total (S/)
Equipos				
Computadoras portátiles	Uso compartido (propiedad de los investigadores)	2	0	0
Escáner multifuncional	Propio o facilitado por organización participante (por validar)	1	0	0
Software				
Sistema operativo, ofimática	Software libre o licencias institucionales (por validar)	2	0	0
Materiales de oficina				
Papel, tinta, útiles de escritorio	Para impresión de documentos y protocolos	1 lote	150	150
Servicios				
Conexión a Internet	Plan de datos fijo (por mes)	12	80	960
Energía eléctrica	Consumo adicional estimado	12	60	720
Impresiones y empastado del informe final	Unidades de informe	3	100	300
Total				2,130

Nota: Los costos relacionados con el escáner y licencias de software se consideran nulos al emplearse equipos propios y herramientas de código abierto. Este presupuesto es tentativo y deberá ser ajustado cuando se confirmen los recursos disponibles.

VI. REFERENCIAS BIBLIOGRÁFICAS

La lista que se presenta incluye las fuentes normativas, técnicas y metodológicas empleadas en la elaboración del plan y que serán citadas en el informe final. Al tratarse de un plan, algunos antecedentes específicos serán incorporados tras la revisión sistemática de literatura; las referencias aquí expuestas ya han sido verificadas o serán confirmadas en su texto completo durante el desarrollo de la tesis.

Congreso de la República del Perú. (2011). *Ley N.º 29733, Ley de Protección de Datos Personales*. El Peruano. <https://leyes.congreso.gob.pe>

International Organization for Standardization. (2016). *ISO 15489-1:2016 - Information and documentation - Records management - Part 1: Concepts and principles*.

National Institute of Standards and Technology. (2001). *FIPS PUB 197: Advanced Encryption Standard (AES)*. U.S. Department of Commerce. <https://nvlpubs.nist.gov/nistpubs/FIPS/NIST.FIPS.197.pdf>

Smith, R. (2007). An overview of the Tesseract OCR engine. En *Proceedings of the Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)* (pp. 629-633). IEEE. <https://doi.org/10.1109/ICDAR.2007.4376991>

Universidad Privada de Tacna, Facultad de Ingeniería. (2022). *Manual para el desarrollo de trabajos de investigación*.

Nota para la versión final: Las referencias a artículos sobre clasificación automática de documentos, seguridad en flujos documentales y sincronización en la nube, así como los antecedentes empíricos citados en el marco teórico, se añadirán una vez localizados y analizados los textos completos correspondientes. Todas las fuentes serán presentadas en estricto formato APA 7.^a edición.

ANEXOS

Anexo 1: Matriz de consistencia (Tabla 2)

Problema	Objetivo	Hipótesis	Variables	Dimensiones	Indicadores	Metodología
PG: ¿En qué medida un ecosistema de gestión documental inteligente con clasificación autónoma y ciberseguridad mejora la eficiencia, precisión, seguridad y trazabilidad de los procesos documentales en organizaciones de servicios de Tacna, 2026?	OG: Determinar el efecto de la implementación de un ecosistema de gestión documental inteligente, clasificación autónoma y ciberseguridad en la mejora de la eficiencia, precisión, seguridad y trazabilidad de los procesos documentales en organizaciones de servicios de Tacna, 2026.	HG: La implementación de un ecosistema de gestión documental inteligente, clasificación autónoma y ciberseguridad mejora significativamente la eficiencia, precisión, seguridad y trazabilidad de los procesos documentales en organizaciones de servicios de Tacna, 2026.	VI: Ecosistema de gestión documental inteligente, clasificación autónoma y ciberseguridad. VD: Eficiencia, precisión, seguridad, trazabilidad.	VD: Tiempo de procesamiento, exactitud de clasificación, cifrado automático, completitud de logs y errores de sincronización.	Tiempo promedio por documento; porcentaje de clasificación correcta; porcentaje de documentos sensibles cifrados; porcentaje de completitud de logs; tasa de errores de sincronización.	Investigación aplicada, enfoque cuantitativo, diseño pre-experimental (pretest-posttest de un solo grupo). Población: lotes documentales de organizaciones de servicios de Tacna; muestra: 120 documentos administrativos en formato PDF.
PE1: ¿En qué medida el ecosistema reduce el tiempo promedio de procesamiento por documento?	OE1: Determinar la reducción del tiempo promedio de procesamiento por documento tras la implementación del ecosistema.	HE1: La implementación del ecosistema reduce significativamente el tiempo promedio de procesamiento por documento en comparación con el proceso manual.	VD: Eficiencia	Tiempo de digitalización y clasificación	Tiempo promedio por documento (segundos)	Se empleará una ficha de observación de tiempos, con cronómetro digital, aplicada en el pretest y posttest.
PE2: ¿Cuál es la precisión de la clasificación autónoma alcanzada por el ecosistema?	OE2: Medir la precisión alcanzada por la clasificación autónoma de documentos.	HE2: La clasificación autónoma alcanza una precisión superior al 90 % en la identificación del tipo documental.	VD: Precisión de clasificación	Exactitud de la clasificación automática	Porcentaje de documentos clasificados correctamente; tasa de falsos positivos y falsos negativos	Se utilizará una plantilla de registro de clasificación, contrastando la etiqueta asignada por el sistema con la etiqueta de referencia asignada por un experto.

Problema	Objetivo	Hipótesis	Variables	Dimensiones	Indicadores	Metodología
PE3: ¿Qué proporción de documentos sensibles es cifrada automáticamente por el ecosistema?	OE3: Cuantificar la proporción de documentos sensibles que son cifrados automáticamente por el ecosistema.	HE3: El ecosistema cifra automáticamente e al menos el 95 % de los documentos que contienen información sensible.	VD: Seguridad (cifrado)	Cifrado automático de PDF sensibles	Porcentaje de documentos sensibles cifrados automáticamente	Se aplicará un registro de cifrado, verificando la presencia del cifrado AES-256 en los documentos que contienen palabras u oraciones llave sensibles.
PE4: ¿Cuál es el nivel de completitud de los logs y los errores de sincronización del ecosistema?	OE4: Evaluar el nivel de completitud de los logs de auditoría y la tasa de errores en la sincronización.	HE4: Los logs de auditoría registran el 100 % de las acciones y la sincronización presenta una tasa de error menor al 2 %.	VD: Trazabilidad	Completitud de logs y calidad de sincronización	Porcentaje de acciones registradas en el log; tasa de errores de sincronización	Se usará una ficha de verificación de logs (conteo de acciones documentadas versus acciones ejecutadas) y un control de registros de errores de sincronización en Google Drive/Dropbox.

Nota. PG: problema general; OG: objetivo general; HG: hipótesis general; VI: variable independiente; VD: variable dependiente. Todas las VD y sus indicadores se miden en los momentos pretest y postest sobre la misma muestra documental.

Anexo 2: Instrumentos de recolección de datos

Para capturar los indicadores definidos en la operacionalización de variables se emplearán instrumentos de observación estructurada, los cuales serán elaborados por los tesisas y sometidos a un proceso de validación de contenido mediante juicio de tres expertos en gestión documental, informática y metodología de la investigación. A continuación se describen los instrumentos previstos:

- **Anexo 2.A - Ficha de observación de tiempos de procesamiento:** registra para cada documento: identificador del documento, operador que ejecuta la sesión, hora de inicio de la captura (o de la inclusión en carpeta vigilada), hora de finalización del proceso (clasificación, renombrado, cifrado y archivo en la estructura de carpetas), tiempo total en segundos y observaciones eventuales. Se utilizará un cronómetro digital de precisión, complementado con las marcas de tiempo del propio sistema cuando esté disponible, para calcular el tiempo promedio por documento en el pretest (proceso manual) y en el postest (proceso automatizado).
- **Anexo 2.B - Plantilla de registro de precisión de clasificación:** diseñada para cada lote procesado, contiene las columnas: código del documento, tipo documental de referencia (asignado por un experto humano a partir de la imagen original), tipo documental inferido por el módulo de IA, coincidencia (sí/no) y naturaleza del error (falso positivo o falso negativo). A partir de este registro se calculará el porcentaje de clasificación correcta, así como las tasas de falsos positivos y falsos negativos, tanto en la condición manual como después de la implementación.
- **Anexo 2.C - Registro de cifrado automático de documentos sensibles:** se emplea para contabilizar el cifrado efectivo. Incluye los campos: identificador del documento, contiene palabra/oración llave sensible (sí/no), cifrado aplicado (sí/no), algoritmo (AES-256), y hash resultante. Se verificará, de manera manual y automatizada, que todos los documentos que contengan las cadenas sensibles definidas en las reglas de cifrado hayan sido protegidos. El indicador será el porcentaje de documentos sensibles efectivamente cifrados.

- **Anexo 2.D - Ficha de verificación de logs de auditoría:** se basa en el registro inmutable generado por el ecosistema. Para un conjunto de acciones ejecutadas (captura, OCR, clasificación, cifrado, sincronización), se verificará la presencia del registro correspondiente en el log. La ficha recoge: identificador de la acción, tipo de acción, registrada en log (sí/no), integridad del hash de encadenamiento y observaciones. Se calculará el porcentaje de completitud.
- **Anexo 2.E - Control de errores de sincronización:** hoja de registro destinada a anotar las incidencias durante la sincronización con Google Drive o Dropbox al cierre de cada sesión. Contiene: sesión, número de documentos pendientes de sincronizar, número de documentos sincronizados exitosamente, número de errores, código de error, y tiempo de resincronización. La tasa de error será el cociente entre documentos con error y el total de documentos sincronizados, expresado en porcentaje.

Todos estos instrumentos serán aplicados en dos momentos, antes y después de la implementación del ecosistema, guardando idénticos procedimientos de recolección para garantizar la comparabilidad.

Anexo 3: Estructura del log de auditoría inmutable

El ecosistema propuesto incorpora un mecanismo de registro encadenado que garantiza la integridad y la inmutabilidad de las acciones, cumpliendo con los principios de trazabilidad exigidos por la Ley N.º 29733 y la ISO 15489-1. La estructura lógica de cada entrada del log contiene los siguientes campos:

- **id_log:** identificador único secuencial.
- **timestamp:** fecha y hora exacta de la acción, generada por el sistema en UTC-5, con precisión de milisegundos.
- **id_sesion:** identificador de la sesión de digitalización.
- **usuario:** identificador del operador autenticado (o sistema si la acción es automática).
- **id_documento:** nombre único asignado al archivo PDF dentro del repositorio.
- **accion:** tipo de evento registrado. Valores posibles: CAPTURA, OCR, PREPROCESADO, CLASIFICACION, RENOMBRADO, CIFRADO, SINCRONIZACION, ERROR, MOVIMIENTO_PENDIENTES.
- **resultado:** estado de la acción (EXITO, FALLO, PENDIENTE).
- **detalle:** cadena descriptiva que incluye, por ejemplo, el tipo documental inferido, la regla de cifrado activada o el código de error de sincronización.
- **hash_documento:** valor hash SHA-256 del archivo PDF en el estado inmediatamente posterior a la acción.
- **hash_anterior:** hash SHA-256 de la entrada de log inmediatamente precedente, formando así una cadena inmutable.
- **firma_digital:** firma electrónica del registro, aplicada por el módulo de seguridad del ecosistema para detectar cualquier alteración posterior.

La tabla de log se almacena en una base de datos local con permisos de solo adición (*append-only*) y se respalda periódicamente en la nube junto con los documentos, asegurando la disponibilidad para auditorías y la verificación de la integridad mediante el recálculo de la cadena de hashes. Esta estructura garantiza que los indicadores de completitud y trazabilidad puedan ser auditados de manera objetiva durante la fase experimental.

Anexo 1 - Matriz de consistencia (Tabla 2) resume la articulación entre problema, objetivos, hipótesis, variables, indicadores y metodología. Los Anexos 2 y 3 detallan los instrumentos de recolección y la estructura de auditoría, en coherencia con el diseño pre-experimental y los supuestos del estudio.