

**UNIVERSIDAD PRIVADA DE TACNA
FACULTAD DE INGENIERIA
ESCUELA PROFESIONAL DE INGENIERIA DE SISTEMAS**

PLAN DE TRABAJO DE INVESTIGACION

**"ECOSISTEMA DE GESTIÓN DOCUMENTAL INTELIGENTE
CON CLASIFICACIÓN AUTÓNOMA Y CIBERSEGURIDAD
PARA ORGANIZACIONES DE SERVICIOS DE TACNA, 2026"**

PARA OPTAR:

TITULO PROFESIONAL DE INGENIERIA DE SISTEMAS

PRESENTADO POR:

ca2022074266@virtual.upt.pe

TACNA - PERU

2026

INDICE

1. Diagnóstico de suficiencia	5
2. Plan de Tesis según Manual FAING 2022	5
I. DATOS GENERALES	5
1.1 Título (propuesto, por validar)	5
1.2 Área de Investigación (por validar): Ingeniería de Sistemas e Informática.	5
1.3 Línea de Investigación (por validar): Sistemas de Información y Gestión del Conocimiento / Ciberseguridad.	5
1.4 Autor (por validar): [Nombre del estudiante]	5
1.5 Asesor (por validar): [Nombre del asesor]	5
II. PROBLEMA DE INVESTIGACIÓN	5
2.1 Descripción del problema	5
2.2 Formulación del problema	5
2.3 Justificación	6
2.4 Objetivos	6
2.5 Hipótesis (aplicable por tratarse de un estudio aplicado, nivel aplicativo)	6
2.6 Variables	6
2.7 Operacionalización de variables (tabla preliminar, por validar con el asesor)	6
2.8 Tipo de investigación	7
2.9 Nivel de investigación	7
III. MARCO TEÓRICO	7
3.1 Antecedentes de la investigación (por validar - se requiere búsqueda en bases académicas)	7
3.2 Bases teóricas (estructura propuesta)	7
3.3 Definición de términos	8
IV. MARCO METODOLÓGICO	8
4.1 Diseño de investigación	8

4.2 Acciones para ejecutar la investigación	8
1. Seleccionar una organización de servicios en Tacna que participe voluntariamente (por validar).8	
2. Configurar el entorno de pre-test: medir tiempos, precisión manual, registro de logs manuales durante dos semanas.	8
3. Desarrollar el prototipo del ecosistema según la arquitectura descrita (OCR local + clasificador NLP + detector de sensibles + cifrador + sincronizador + logger inmutable).	8
4. Implementar el ecosistema en el mismo entorno y capacitar a los operadores.	8
5. Ejecutar el post-test durante un periodo equivalente, registrando las mismas métricas.	8
6. Comparar resultados y contrastar hipótesis mediante estadística inferencial.	8
4.3 Población y muestra	9
4.4 Materiales e instrumentos	9
4.5 Técnicas de análisis de datos	9
V. ASPECTOS ADMINISTRATIVOS	9
5.1 Cronograma de actividades (por validar - se sugiere duración total de 8 meses)	9
5.2 Recursos humanos	10
5.3 Presupuesto y financiamiento (estimación preliminar, por validar)	10
VI. REFERENCIAS BIBLIOGRÁFICAS	10
3. Matriz de consistencia preliminar	11
4. Riesgos metodológicos y datos por validar	11
1. Título definitivo (elegir una alternativa o proponer ajuste).	11
2. Área y línea de investigación en el registro de FAING.	11
3. Nombre completo del autor y del asesor.	12
4. Confirmación de la población accesible y el procedimiento de muestreo.	12
5. Viabilidad del desarrollo del prototipo en el tiempo del plan (meses 3-5).	12

6. Instrumentos: especificar si se utilizará software libre específico (Tesseract, scikit-learn, PyPDF2) y cómo se construirá la matriz ground truth.	12
7. Aceptación formal de la organización participante (carta de consentimiento).	12
5. Propuestas concretas para cerrar vacíos	12
6. Referencias candidatas (descartadas) y búsqueda académica sugerida	12
1. "digital document management" AND "OCR" AND "classification"	12
2. "automated document classification" AND "NLP"	12
3. "document security" AND "automatic encryption" AND "PDF"	12
4. "immutable logs" AND "audit trail"	12
5. "gestión documental inteligente" (en SciELO para contexto latinoamericano)	12

1. Diagnóstico de suficiencia

- Puntaje: 80/100
- Fase: flujo_manual_faing
- Información completada por el estudiante: título de proyecto, descripción funcional, supuestos metodológicos (diseño, muestra, indicadores).
- Vacíos detectados: falta definición de título formal, área y línea de investigación, datos del autor/asesor, antecedentes específicos, población precisa y validación de instrumentos.
- Las referencias candidatas no guardan relación temática, por lo que serán descartadas.

2. Plan de Tesis según Manual FAING 2022

I. DATOS GENERALES

1.1 Título (propuesto, por validar)

"Ecosistema de gestión documental inteligente con clasificación autónoma y ciberseguridad para organizaciones de servicios de Tacna, 2026"

Alternativas por validar (ajustadas a extensión): a) *"Ecosistema inteligente de gestión documental con clasificación IA y cifrado automático, Tacna 2026"* (12 palabras) b) *"Gestión documental autónoma y segura para organizaciones de servicios, Tacna 2026"* (10 palabras) c) *"Sistema de clasificación y cifrado automático de documentos administrativos, Tacna 2026"* (11 palabras)

1.2 Área de Investigación (por validar): Ingeniería de Sistemas e Informática.

1.3 Línea de Investigación (por validar): Sistemas de Información y Gestión del Conocimiento / Ciberseguridad.

1.4 Autor (por validar): [Nombre del estudiante]

1.5 Asesor (por validar): [Nombre del asesor]

II. PROBLEMA DE INVESTIGACIÓN

2.1 Descripción del problema

En las organizaciones de servicios de Tacna (públicas y privadas) se manejan diariamente documentos administrativos físicos que deben digitalizarse, clasificarse y almacenarse de forma segura. Sin embargo, carecen de procesos estandarizados para ello. Actualmente, la digitalización es manual, la clasificación depende del criterio del operador, el cifrado de información sensible no se aplica o es esporádico, y la trazabilidad mediante registros de operación es casi inexistente. Esto genera: errores en la categorización, demoras en la localización de documentos, exposición de datos personales o estratégicos, pérdida del historial de cambios y desorganización en repositorios locales y en la nube. La causa principal es la ausencia de un sistema que integre captura, OCR, clasificación automática por IA, detección de contenido sensible, cifrado automático y sincronización auditada. La solución propuesta consiste en implementar un ecosistema que articule esos componentes y medir su impacto en la eficiencia y seguridad de la gestión documental.

2.2 Formulación del problema

Problema general: ¿En qué medida la implementación de un ecosistema de gestión documental inteligente basado en clasificación autónoma y ciberseguridad mejora la eficiencia y la protección de documentos administrativos en organizaciones de servicios de Tacna, 2026?

Problemas específicos: PE1: ¿Cuál es la diferencia en el tiempo promedio de procesamiento por documento antes y después de la implementación del ecosistema? PE2: ¿Qué precisión alcanza la clasificación autónoma de los documentos según tipo y presencia de contenido sensible? PE3: ¿En qué porcentaje se logra el cifrado automático de documentos que contienen datos sensibles una vez operado el ecosistema? PE4: ¿Cuál es la completitud de los logs de auditoría y la tasa de errores en la sincronización con plataformas externas bajo el nuevo ecosistema?

2.3 Justificación

- *Social:* Reduce el riesgo de filtración de datos personales de ciudadanos y clientes, reforzando la confianza en las organizaciones de servicios.
- *Económica:* Disminuye costos operativos por retrabajos, extravío de documentos y horas-hombre dedicadas a clasificación manual.
- *Científico-tecnológica:* Aporta evidencia empírica sobre la integración de OCR + IA local + cifrado automático en contextos organizacionales reales, un campo con escasos estudios en la región.
- *Ambiental:* Al optimizar la digitalización, se reduce el uso de papel y la impresión innecesaria.

2.4 Objetivos

Objetivo general: Determinar el impacto de la implementación de un ecosistema de gestión documental inteligente con clasificación autónoma y ciberseguridad sobre la eficiencia y la seguridad en el manejo de documentos administrativos de organizaciones de servicios de Tacna, 2026.

Objetivos específicos: OE1: Comparar el tiempo promedio de procesamiento por documento entre el escenario manual actual y el escenario con el ecosistema implementado. OE2: Evaluar la precisión de la clasificación autónoma de documentos por tipo y detección de contenido sensible. OE3: Cuantificar el porcentaje de documentos sensibles que son cifrados automáticamente por el ecosistema. OE4: Verificar la completitud de los logs de auditoría y la tasa de errores en la sincronización con repositorios en la nube.

2.5 Hipótesis (aplicable por tratarse de un estudio aplicado, nivel aplicativo)

Hipótesis general: La implementación del ecosistema de gestión documental inteligente mejora significativamente la eficiencia (reducción de tiempo) y la seguridad (precisión de clasificación, cifrado automático, integridad de logs y sincronización) en las organizaciones de servicios de Tacna.

Hipótesis específicas: HE1: El tiempo promedio de procesamiento por documento se reduce en al menos un 40 % tras la implementación del ecosistema. HE2: La precisión de la clasificación autónoma supera el 90 % (medida como F1-score). HE3: El ecosistema cifra automáticamente al menos el 95 % de los documentos que contienen palabras u oraciones llave sensibles. HE4: Los logs de auditoría alcanzan un 100 % de completitud y los errores de sincronización son inferiores al 1 %.

2.6 Variables

- **Variable independiente:** Ecosistema de gestión documental inteligente (presencia/ausencia).
- **Variables dependientes:**
 - VD1: Tiempo promedio de procesamiento por documento (minutos).
 - VD2: Precisión de clasificación (%).
 - VD3: Porcentaje de documentos sensibles cifrados (%).
 - VD4: Completitud de logs (%).
 - VD5: Tasa de errores de sincronización (%).

2.7 Operacionalización de variables (tabla preliminar, por validar con el asesor)

Variable	Indicador	Escala
VI: Ecosistema	Fase: Pre-test (manual) / Post-test (con ecosistema)	Nominal
VD1: Tiempo de procesamiento	Minutos transcurridos desde la captura hasta el almacenamiento final	Razón
VD2: Precisión de clasificación	(Documentos correctamente clasificados / Total documentos procesados) x 100	Razón
VD3: Cifrado automático de sensibles	(Documentos sensibles cifrados / Documentos sensibles detectados) x 100	Razón
VD4: Completitud de logs	(Registros de eventos registrados / Total de eventos esperados) x 100	Razón
VD5: Errores de sincronización	(Intentos de sincronización fallidos / Total intentos) x 100	Razón

2.8 Tipo de investigación

Aplicada, porque busca resolver un problema práctico mediante el diseño e implementación de una solución tecnológica.

2.9 Nivel de investigación

Aplicativo (según el manual FAING), ya que se implementa un prototipo funcional y se evalúan sus efectos sobre variables dependientes en un entorno real.

III. MARCO TEÓRICO

3.1 Antecedentes de la investigación (por validar - se requiere búsqueda en bases académicas)

Las referencias candidatas provistas no guardan relación con el tema. Se recomienda buscar artículos científicos publicados entre 2019-2024 en Scopus, IEEE Xplore, SciELO y Google Scholar utilizando combinaciones de términos como:

- "intelligent document management" AND "OCR"
- "automated document classification" AND "machine learning"
- "document security" AND "automatic encryption"
- "digitalización documental" AND "clasificación automática"
- "information security" AND "document management system"

Antecedente tentativo por validar (el estudiante deberá localizar el texto completo y verificar su pertinencia):

- Autor et al. (2022). *Automated document classification system for administrative archives*. Journal of Information Systems Engineering. (Referencia ficticia, reemplazar una vez encontrada la real).

3.2 Bases teóricas (estructura propuesta)

- Gestión documental y ciclo de vida del documento (ISO 15489).
- Digitalización y captura de documentos: estándares TWAIN/WIA, tecnologías de escaneo.
- Reconocimiento óptico de caracteres (OCR): fundamentos, motores libres (Tesseract) y precisión.
- Clasificación automática de documentos: procesamiento de lenguaje natural (NLP), modelos supervisados (Naïve Bayes, SVM, transformers ligeros).

- Detección de contenido sensible: expresiones regulares, listas de palabras clave, NER (reconocimiento de entidades).
- Ciberseguridad documental: cifrado simétrico (AES-256), cifrado de PDF, integridad con hashing.
- Logs inmutables para auditoría: principios de no repudio y cadena de custodia digital.
- Sincronización segura con servicios de nube (API de Google Drive, Dropbox).

3.3 Definición de términos

- **Ecosistema de gestión documental inteligente:** Sistema integrado que abarca captura, procesamiento, almacenamiento y protección de documentos, con componentes de IA.
- **Clasificación autónoma:** Asignación de categorías a documentos mediante algoritmos sin intervención humana directa.
- **OCR:** Tecnología que convierte imágenes de texto en texto legible por máquina.
- **Cifrado automático:** Proceso de protección de un archivo mediante algoritmos criptográficos activado por reglas predefinidas.
- **Log inmutable:** Registro cronológico de eventos que no puede ser modificado retroactivamente.
- **Falso positivo/negativo en clasificación:** Error donde un documento es asignado a una categoría incorrecta (falso positivo) o no se detecta su pertenencia a la categoría correcta (falso negativo).

IV. MARCO METODOLÓGICO

4.1 Diseño de investigación

Diseño pre-experimental de un solo grupo con medición antes-después (pre-test y post-test). Esquema: $G: O1 \rightarrow X \rightarrow O2$, donde $O1$ es la medición de las variables dependientes bajo el proceso manual actual, X la implementación del ecosistema, y $O2$ la medición posterior sobre la misma muestra de documentos.

4.2 Acciones para ejecutar la investigación

1. **Seleccionar una organización de servicios en Tacna que participe voluntariamente (por validar).**
2. **Configurar el entorno de pre-test: medir tiempos, precisión manual, registro de logs manuales durante dos semanas.**
3. **Desarrollar el prototipo del ecosistema según la arquitectura descrita (OCR local + clasificador NLP + detector de sensibles + cifrador + sincronizador + logger inmutable).**
4. **Implementar el ecosistema en el mismo entorno y capacitar a los operadores.**
5. **Ejecutar el post-test durante un periodo equivalente, registrando las mismas métricas.**
6. **Comparar resultados y contrastar hipótesis mediante estadística inferencial.**

4.3 Población y muestra

- **Población:** Todos los documentos administrativos generados por las organizaciones de servicios de Tacna durante un horizonte temporal típico (ej., un trimestre).
- **Muestra** (*por validar el tamaño exacto con base en una prueba piloto o fórmula de poblaciones infinitas*): Tentativamente 120 documentos, seleccionados mediante muestreo no probabilístico intencional, que cubran diferentes tipos documentales (facturas, contratos, informes, oficios, etc.) y distintos niveles de sensibilidad (con y sin datos personales).

4.4 Materiales e instrumentos

- **Materiales:** Computador con capacidad de procesamiento local, escáner compatible con TWAIN/WIA, espacio en disco, conexión a internet para sincronización.
- **Instrumentos:**
 - Ficha de registro de tiempo de procesamiento (cronómetro digital y planilla).
 - Matriz de clasificación de referencia (ground truth) elaborada por expertos en gestión documental de la organización.
 - Lista de palabras/oraciones llave sensibles definidas según normativa peruana de protección de datos (LPDP).
 - Script de análisis automático del logger del ecosistema para extraer métricas de completitud y errores de sincronización.
- **Validación por juicio de expertos** (por realizar): la matriz de clasificación y las listas llave serán revisadas por dos especialistas en gestión documental y en seguridad de la información.

4.5 Técnicas de análisis de datos

- Estadística descriptiva: cálculo de medias, medianas, desviaciones estándar y porcentajes para cada indicador en pre-test y post-test.
- Prueba de normalidad (Shapiro-Wilk).
- Si hay normalidad, prueba t-Student para muestras emparejadas para comparar tiempos y precisión.
- Si no hay normalidad, prueba de Wilcoxon.
- Para los indicadores de porcentaje (cifrado, completitud, errores) se analizarán diferencias de proporciones con estadístico z.
- El nivel de significancia se fija en $\alpha = 0.05$. Los análisis se realizarán en SPSS o R.

V. ASPECTOS ADMINISTRATIVOS

5.1 Cronograma de actividades (por validar - se sugiere duración total de 8 meses)

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8
1. Revisión bibliográfica	X	X						
2. Diseño del ecosistema	X	X						
3. Desarrollo del prototipo		X	X	X				

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8
4. Coordinación con organización		X						
5. Pre-test y recolección línea base			X					
6. Implementación y capacitación				X				
7. Post-test					X			
8. Análisis de datos						X	X	
9. Redacción del informe final						X	X	X
10. Presentación y defensa								X

5.2 Recursos humanos

- Tesista: responsable de todas las etapas.
- Asesor: orientación metodológica y revisión.
- Dos operadores de la organización: ejecución de digitalización en pre-test y post-test (por validar si se requiere capacitación previa).
- Dos jueces expertos: para validar instrumentos.

5.3 Presupuesto y financiamiento (estimación preliminar, por validar)

Concepto	Costo (\$/.)
Materiales de oficina	200
Almacenamiento temporal en nube (1 año)	300
Licencias de software (si se usa librerías pagas)	0 (se prioriza open source)
Movilidad y viáticos	150
Imprevistos	100
Total	750
Financiamiento: Recursos propios del tesista	

VI. REFERENCIAS BIBLIOGRÁFICAS

(Esta sección se completará durante el desarrollo del plan. Las referencias candidatas provistas no son pertinentes; se sugiere iniciar la búsqueda con los términos indicados en 3.1. A continuación un ejemplo de formato APA 7ª edición que debe llenarse con artículos genuinos.)

Autor, A. A. (año). Título del artículo. Nombre de la Revista, volumen(número), páginas. DOI/URL

Por el momento, se declara **sección en blanco - por completar**.

3. Matriz de consistencia preliminar

Problema general	Objetivo general	Hipótesis general	Variables	Metodología
¿En qué medida la implementación de un ecosistema de gestión documental inteligente con clasificación autónoma y ciberseguridad mejora la eficiencia y la protección de documentos administrativos en organizaciones de servicios de Tacna, 2026?	Determinar el impacto de la implementación del ecosistema sobre la eficiencia y seguridad en la gestión documental.	La implementación del ecosistema mejora significativamente la eficiencia y seguridad.	VI: Ecosistema (pre/post). VDs: tiempo, precisión, % cifrado, logs, errores sinc.	Enfoque: cuantitativo. Tipo: aplicada. Nivel: aplicativo. Diseño: pre-experimental antes-después. Muestra: 120 docs. Instrumentos: fichas, logs, matriz de clasificación. Análisis: t-Student/Wilcoxon y comparación de proporciones.
PE1	OE1	HE1	VD1: Tiempo promedio	
¿Diferencia en tiempo de procesamiento antes y después?	Comparar el tiempo promedio entre pre-test y post-test.	El tiempo se reduce al menos 40 % tras implementación.		
PE2	OE2	HE2	VD2: Precisión clasificación	
¿Precisión de la clasificación autónoma?	Evaluar la precisión de la clasificación automática.	Precisión > 90 % (F1-score).		
PE3	OE3	HE3	VD3: % cifrado sensibles	
¿Porcentaje de documentos sensibles cifrados automáticamente?	Cuantificar el porcentaje de cifrado automático de docs. sensibles.	Al menos 95 % de sensibles son cifrados automáticamente.		
PE4	OE4	HE4	VD4: completitud logs; VD5: errores sinc.	
¿Completitud de logs y errores de sincronización?	Verificar completitud de logs y tasa de errores de sincronización.	Logs 100 % completos; errores de sinc. < 1 %.		

4. Riesgos metodológicos y datos por validar

Riesgos metodológicos identificados:

- La muestra de 120 documentos puede resultar insuficiente para detectar diferencias pequeñas; se recomienda una prueba piloto para ajustar tamaño.
- El diseño pre-experimental carece de grupo control, lo que limita la atribución causal; se mitigará con una línea base robusta y control de variables extrañas (mismo periodo, mismos operadores).
- La dependencia de una sola organización puede restar validez externa; se sugiere replicar luego en otra entidad, aunque no forma parte del presente plan.

Datos que necesitan validación por el estudiante/asesor:

1. Título definitivo (elegir una alternativa o proponer ajuste).

2. Área y línea de investigación en el registro de FAING.

3. Nombre completo del autor y del asesor.

4. Confirmación de la población accesible y el procedimiento de muestreo.

5. Viabilidad del desarrollo del prototipo en el tiempo del plan (meses 3-5).

6. Instrumentos: especificar si se utilizará software libre específico (Tesseract, scikit-learn, PyPDF2) y cómo se construirá la matriz ground truth.

7. Aceptación formal de la organización participante (carta de consentimiento).

5. Propuestas concretas para cerrar vacíos

- **Antecedentes:** Iniciar una búsqueda sistemática en Scopus y IEEE Xplore con la ecuación: TITLE-ABS-KEY ("document management" AND ("automatic classification" OR "smart") AND (security OR encryption)). Filtrar por últimos 5 años.
- **Instrumentos:** Elaborar una ficha de registro de tiempo (formato Google Sheets que capture hora de inicio y fin) y una matriz de clasificación consensuada con dos expertos de la organización.
- **Detector de sensibles:** Definir la lista de palabras llave basada en la Ley de Protección de Datos Personales del Perú (Ley N° 29733) y su reglamento.
- **Logs:** Diseñar la estructura del log inmutable como un archivo CSV con hash encadenado por registro, garantizando integridad.

6. Referencias candidatas (descartadas) y búsqueda académica sugerida

Las referencias candidatas proporcionadas (Escobar, 2019; Masó & Pons, 2025; Pinto, 2022; Jiménez & Pino, 2018; Castillo, 2019) no presentan vinculación temática con el proyecto. Se descartan.

Términos de búsqueda académica concretos para alimentar el marco teórico:

1. "digital document management" AND "OCR" AND "classification"

2. "automated document classification" AND "NLP"

3. "document security" AND "automatic encryption" AND "PDF"

4. "immutable logs" AND "audit trail"

5. "gestión documental inteligente" (en SciELO para contexto latinoamericano)

El plan podrá enriquecerse una vez localizados 3 o 4 artículos de estos campos. Se recomienda gestionar los textos completos y citarlos en la sección de antecedentes una vez verificados.

Este plan queda listo para revisión del asesor y del estudiante, quienes deberán confirmar los datos marcados como "por validar" y completar los vacíos señalados.